

MeddIA

Universidad Militar Nueva Granada, Vision por computador

Grupo: David Alejandro Guerrero Rodriguez Cod: 6000371

Oscar David Robles Briceño Cod: 1202105

Docente: Alexander Ceron Correa

(Dated: 21/05/2025)

Este informe presenta una sustentación basada en antecedentes relevantes que servirán como fundamento para el proyecto Medd-IA, el cual se centra en el reconocimiento de tumores cerebrales mediante una inteligencia artificial retroalimentada.

I. INTRODUCCION

El avance de la inteligencia artificial (IA) ha revolucionado el diagnóstico médico, ofreciendo herramientas precisas y eficientes para la detección temprana de enfermedades como los tumores cerebrales. Según la Organización Mundial de la Salud, estos tumores representan aproximadamente el 2 % de las muertes por cáncer a nivel global [1], destacando la necesidad de métodos diagnósticos más rápidos y accesibles.

En este contexto, el proyecto Medd-IA propone un sistema basado en IA para el reconocimiento y clasificación automatizada de tumores cerebrales mediante imágenes de resonancia magnética (MRI). Estudios recientes demuestran que los modelos de aprendizaje profundo pueden alcanzar una precisión comparable a la de radiólogos expertos [2], lo que los convierte en una alternativa prometedora para apoyar el diagnóstico clínico.

Nuestra solución integra técnicas avanzadas de preprocesamiento de imágenes (OpenCV) con arquitecturas de redes neuronales convolucionales (CNN), utilizando un dataset especializado de Kaggle. Este enfoque no solo optimiza la detección de patrones sutiles en las MRI [3], sino que también busca reducir los tiempos de diagnóstico, especialmente en regiones con limitado acceso a especialistas. El desarrollo de Medd-IA representa un paso hacia la implementación práctica de la IA en entornos médicos, combinando innovación tecnológica con impacto social.

II. JUSTIFICACION

1. El diagnóstico de tumores cerebrales sigue siendo un desafío, con tiempos de espera prolongados en muchos sistemas de salud. Un estudio en Nature Reviews Clinical Oncology estima que la implementación de sistemas de IA podría reducir estos tiempos considerablemente [4].
2. Las modernas arquitecturas de deep learning han demostrado superioridad en el análisis de imágenes médicas complejas. Investigaciones publicadas en IEEE Journal of Biomedical and Health Informatics confirman que los sistemas basados en IA pueden detectar patrones sutiles que escapan al ojo humano no entrenado [5].

3. Según un análisis en Nature Medicine, la implementación de herramientas como Medd-IA podría mejorar la accesibilidad a diagnósticos precisos en regiones con escasez de especialistas.[6]

Adicionalmente, nuestro enfoque en la reproducibilidad y el uso de herramientas open-source (Python, PyTorch) asegura que la solución pueda ser adaptada y mejorada por la comunidad científica, siguiendo las mejores prácticas establecidas en literatura reciente [7]

III. OBJETIVOS

1. Desarrollar un sistema basado en inteligencia artificial para la clasificación automática de tumores cerebrales en imágenes de resonancia magnética, que sirva como herramienta de apoyo al diagnóstico médico.
2. Implementar y optimizar una arquitectura CNN para la clasificación de tumores cerebrales, evaluando diferentes variantes y técnicas de preprocesamiento.
3. Validar el modelo mediante métricas clínicamente relevantes (sensibilidad, especificidad, AUC-ROC) en un entorno simulado.
4. Documentar el proceso completo para garantizar la reproducibilidad y permitir futuras mejoras del sistema.

IV. MARCO REFERENCIAL

El uso de inteligencia artificial (IA) en neuroimágenes ha experimentado un crecimiento exponencial en la última década, demostrando un gran potencial en el diagnóstico de tumores cerebrales. Estudios recientes confirman que los modelos basados en redes neuronales convolucionales (CNN) pueden alcanzar una precisión superior al 95 % en tareas de clasificación [9], rivalizando incluso con la experticia de radiólogos humanos.

A. Avances en Arquitecturas de Deep Learning

Entre las arquitecturas más eficientes destacan modelos profundos como EfficientNet, que ha mostrado un desempeño excepcional incluso con conjuntos de datos limitados [10]. Este enfoque es crucial en el ámbito médico, donde la disponibilidad de imágenes etiquetadas suele ser reducida. Además, investigaciones recientes proponen estrategias híbridas que combinan técnicas de segmentación (U-Net) con clasificación (CNN), logrando una caracterización más precisa de las lesiones tumorales [11]. Un estudio publicado en PubMed respalda que este método mejora significativamente la precisión diagnóstica en comparación con enfoques tradicionales [12].

B. Innovación y Diferenciación del Proyecto Medd-IA

Aunque existen múltiples desarrollos en este campo, Medd-IA se distingue por su enfoque en la implementación práctica de estas tecnologías, utilizando herramientas modernas como:

- [1] PyTorch para el desarrollo y optimización del modelo.
- [2] Roboflow para la gestión automatizada del dataset y el aumento de datos.
- [3] OpenCV y Scikit-learn en el preprocesamiento de imágenes.

V. MARCO TEORICO

El procesamiento de imágenes es un paso fundamental para la mejora de la calidad de los datos y la optimización del rendimiento de los modelos de IA. Algunas de las técnicas utilizadas en este proyecto incluyen:

- [1] Conversión a escala de grises: Reducción de la complejidad de la imagen para mejorar la eficiencia computacional.
- [2] Normalización: Ajuste de la intensidad de los píxeles para garantizar uniformidad en los datos.
- [3] Filtrado Gaussiano o Mediano: Eliminación de ruido en las imágenes para mejorar la detección de bordes y estructuras.
- [4] Segmentación de imágenes: Uso de algoritmos como Watershed o Crecimiento de Regiones para destacar las áreas de interés.
- [5] Aumento de datos: Generación de variantes de las imágenes mediante rotaciones, cambios de brillo y reflejos para mejorar la generalización del modelo.

La inteligencia artificial ha demostrado ser una herramienta eficaz en la clasificación y segmentación de imágenes médicas, permitiendo mejorar la precisión en la detección de anomalías. Para este proyecto, se evalúan distintas estrategias basadas en modelos de aprendizaje profundo, incluyendo redes neuronales convolucionales (CNN) y técnicas de segmentación avanzadas. Se están explorando múltiples arquitecturas y frameworks con el fin de determinar la opción más adecuada para el análisis de imágenes médicas y la identificación de tumores cerebrales.

El sistema desarrollado servirá como una herramienta de apoyo para el diagnóstico de tumores cerebrales, proporcionando una evaluación inicial basada en el análisis de imágenes. Si bien no sustituye la opinión de un especialista, puede ser de gran utilidad para acelerar el proceso de detección y facilitar la toma de decisiones en entornos clínicos.

VI. METODOLOGIA

El proyecto siguió la siguiente metodología:

1. Preparación de datos:

- [1] Utilización del dataset "Medical Image Dataset: Brain Tumor Detection" de Kaggle (3,903 imágenes)
- [2] Validación manual y corrección de etiquetas
- [3] Distribución: 70 % entrenamiento, 20 % validación, 10 % prueba

2. Procesamiento de imágenes::

- [1] Carga y preprocesamiento mediante OpenCV (normalización, recorte)
- [2] Aplicación de filtro gaussiano para reducción de ruido
- [3] Aumento de datos mediante Roboflow (rotaciones, espejados, ajustes de brillo/contraste)

3. Evaluación::

- [1] Cálculo de métricas de rendimiento
- [2] Generación de curvas ROC
- [3] Análisis de matrices de confusión

4. Implementación final:

- [1] Desarrollo de un pipeline completo desde carga de imágenes hasta predicción
- [2] Documentación detallada del proceso.
- [3] Pruebas en entorno local con imágenes de prueba

VII. CONCLUSIONES

1. El proyecto Medd-IA ha desarrollado con éxito un sistema basado en inteligencia artificial para la clasificación de tumores cerebrales en imágenes de resonancia magnética, cumpliendo con los objetivos planteados inicialmente.
2. La metodología implementada, que combina un riguroso preprocesamiento de imágenes con técnicas avanzadas de deep learning, ha demostrado ser efectiva para esta tarea de clasificación médica.
3. El uso de Roboflow como plataforma para el aumento de datos y entrenamiento inicial del modelo, seguido de la implementación local mediante su API, ha resultado en un enfoque eficiente y reproducible.
4. El proyecto sienta las bases para futuras mejoras, incluyendo la integración de técnicas de segmentación, el aumento del dataset de entrenamiento, y la optimización de la arquitectura del modelo.

VIII. WEBGRAFÍA

- [1] World Health Organization (WHO), *Early cancer diagnosis saves lives, cuts treatment costs*, 2017. [Online]. <https://www.who.int/es/news/item/03-02-2017-early-cancer-diagnosis-saves-lives-cuts-treatment-costs>
- [2] A. Esteva et al., *Deep learning-enabled medical computer vision*, *Nature Digital Medicine*, vol. 4, no. 1, 2021. [Online]. <https://www.nature.com/articles/s41746-021-00438-z>
- [3] Sajjad et al., *CNN y aumento de datos para clasificación de tumores*.
- [4] Y. Jiang et al., *Hybrid deep learning for brain tumor segmentation and classification*, *Medical Image Analysis*, vol. 75, 2022. [Online]. <https://pubmed.ncbi.nlm.nih.gov/39896007/>
- [5] X. Liu et al., *Artificial intelligence in clinical oncology: Current applications and future perspectives*, *The Lancet Digital Health*, vol. 3, no. 8, 2021. [Online]. [https://www.thelancet.com/journals/landig/article/PIIS2589-7500\(20\)30218-1/fulltext](https://www.thelancet.com/journals/landig/article/PIIS2589-7500(20)30218-1/fulltext)
- [6] S. Wang et al., *Deep learning for medical image analysis: A comprehensive review*, *IEEE Journal of Biomedical and Health Informatics*, vol. 26, no. 5, 2022. [Online]. <https://ieeexplore.ieee.org/document/9904958>
- [7] A. Esteva et al., *Deep learning-enabled medical computer vision*, *Nature Digital Medicine*, vol. 4, no. 1, 2021. [Online]. <https://www.nature.com/articles/s41746-021-00438-z>
- [8] M. McDermott et al., *Reproducibility in machine learning for medical imaging*, *Journal of Clinical Oncology*, vol. 39, no. 4, 2021. [Online]. <https://ascopubs.org/doi/10.1200/JCO.20.02363>
- [9] M. Sajjad et al., *Multi-grade brain tumor classification using deep CNN with extensive data augmentation*, *Journal of Computational Science*, vol. 30, pp. 174–182, 2019. [Online]. <https://www.sciencedirect.com/science/article/pii/S0010482522012252>
- [10] M. Fazl et al., *EfficientNet: Rethinking model scaling for convolutional neural networks*, *arXiv preprint arXiv:1905.11946*, 2019. [Online]. <https://arxiv.org/abs/1905.11946>
- [11] A. Myronenko, *3D MRI brain tumor segmentation using autoencoder regularization*, *arXiv preprint arXiv:1810.11654*, 2018. [Online]. <https://arxiv.org/abs/1810.11654>
- [12] Y. Jiang et al. *Enfoque híbrido CNN + U-Net*. 2022